Развитие инструментов предиктивной аналитики в целях повышения эффективности мониторинга проектов в сфере жилищного строительства

Ефремов Сергей

Московский физико-технический институт
Физтех-школа прикладной математики и информатики
Кафедра технологий цифровой трансформации

Научный руководитель канд. экон. наук, доц. А;А. Помулев

Москва,
2022 г.

Постановка задачи

Проблема

Для определения потенциально возможных финансовых рисков необходим мониторинг проектов в сфере жилищного строительства

Оценка даты фактической готовности

Предлагается строить прогноз ключевого макропараметра объекта жилищного строительства — даты фактической готовности

Предложение

Проанализировать признаковое описание объектов строительства и построить эффективную регрессионную модель, способную предсказывать дату фактической готовности

Литература

Работы по проектному финансированию

- *Никонова И.А.* Проектный анализ и проектное финансирование // Альпина паблишер, 2012
- *Ассоциация банков России* Финансирование жилищного строительства в рамках достижения национальных целей развития до 2030 года // Аналитические материалы, 2020

Работы по алгоритмам машинного обучения

- *Chen C., Zhang Q., Ma Q., Yu B.* LightGBM-PPI: Predicting protein-protein interactions through LightGBM with multi-information fusion // Chemometrics and Intelligent Laboratory Systems, 2019
- *Friedman, Jerome H.* Greedy Function Approximation: A Gradient Boosting Machine // Annals of Statistics, 2001
- *Gulin A., Karpovich P.* Greedy function optimization in learning rank // YandexLectures , 2009

Входные данные

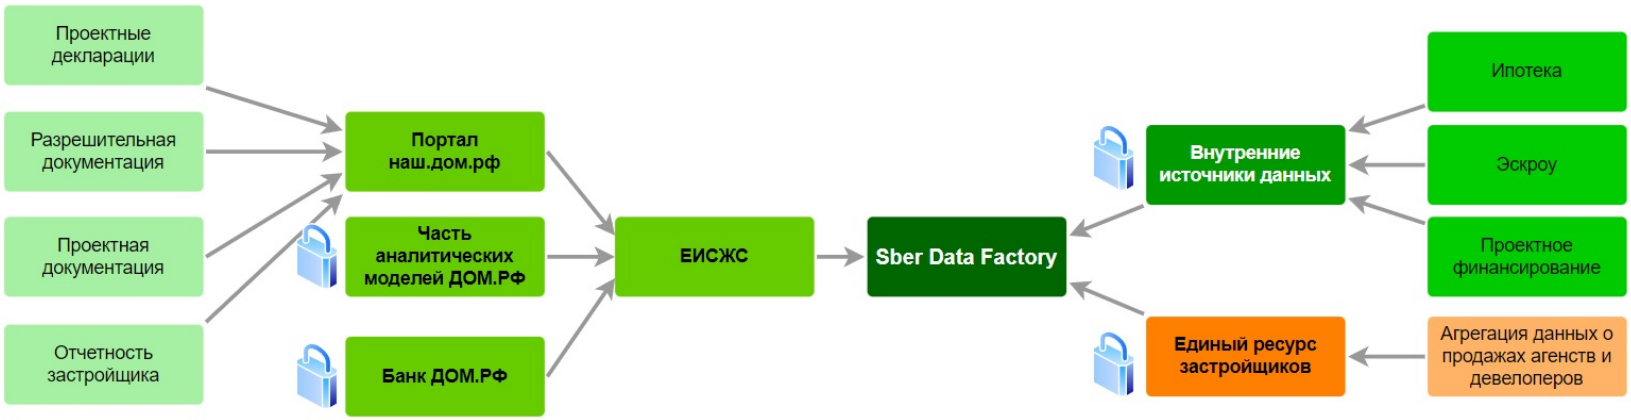

Схема источников данных

Архитектура модели

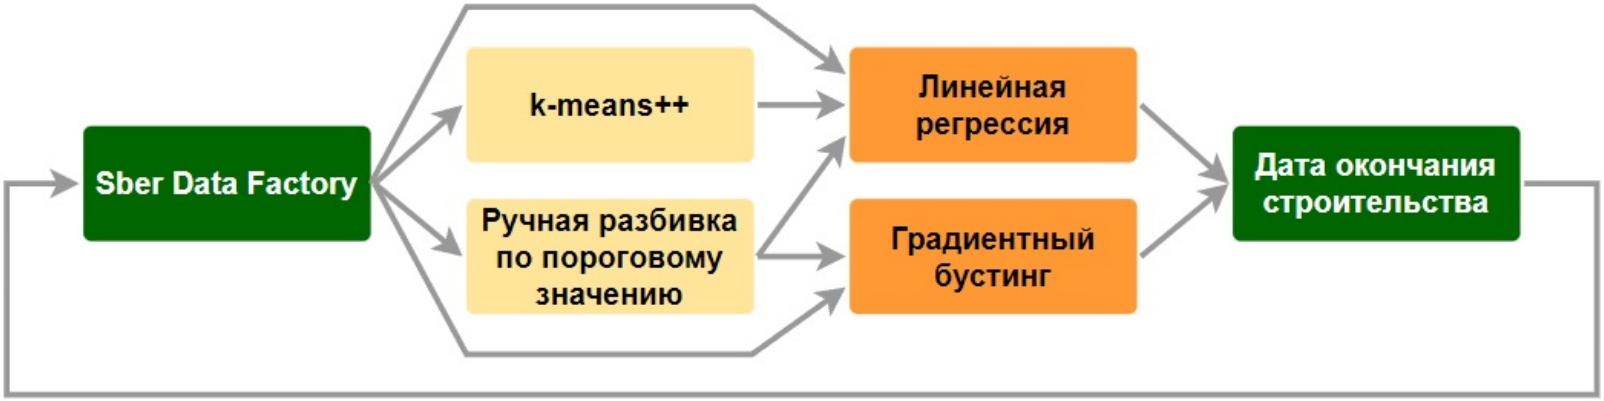

Схематичное изображение исследованных моделей

Предобработка

Метод k -средних

$$a(x_i) = \underset{1 \le k \le K}{\operatorname{argmin}} \rho(x_i, c_k) \quad - \quad \text{критерий принадлежности к кластеру;}$$

$$c_k = \frac{1}{\sum_{i=1}^{l} [a(x_i) = k]} \sum_{i=1}^{l} [a(x_i) = k] x_i \quad - \quad \text{центр кластера}$$

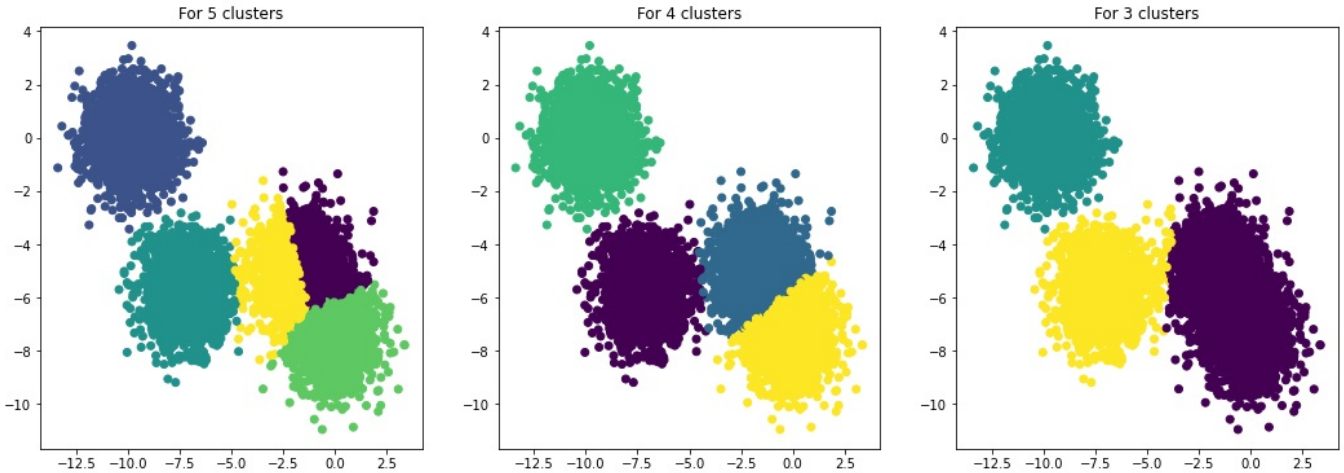

Результат работы k-means для разного количества кластеров

Предобработка

Пороговая классификация

$$a_i \leq \frac{p_j \cdot |R|}{\sum\limits_{k \in R} p_k} \leq a_{i+1}; \qquad a_1 \approx 0,8; a_2 \approx 1,2; a_3 \approx 1,5.$$

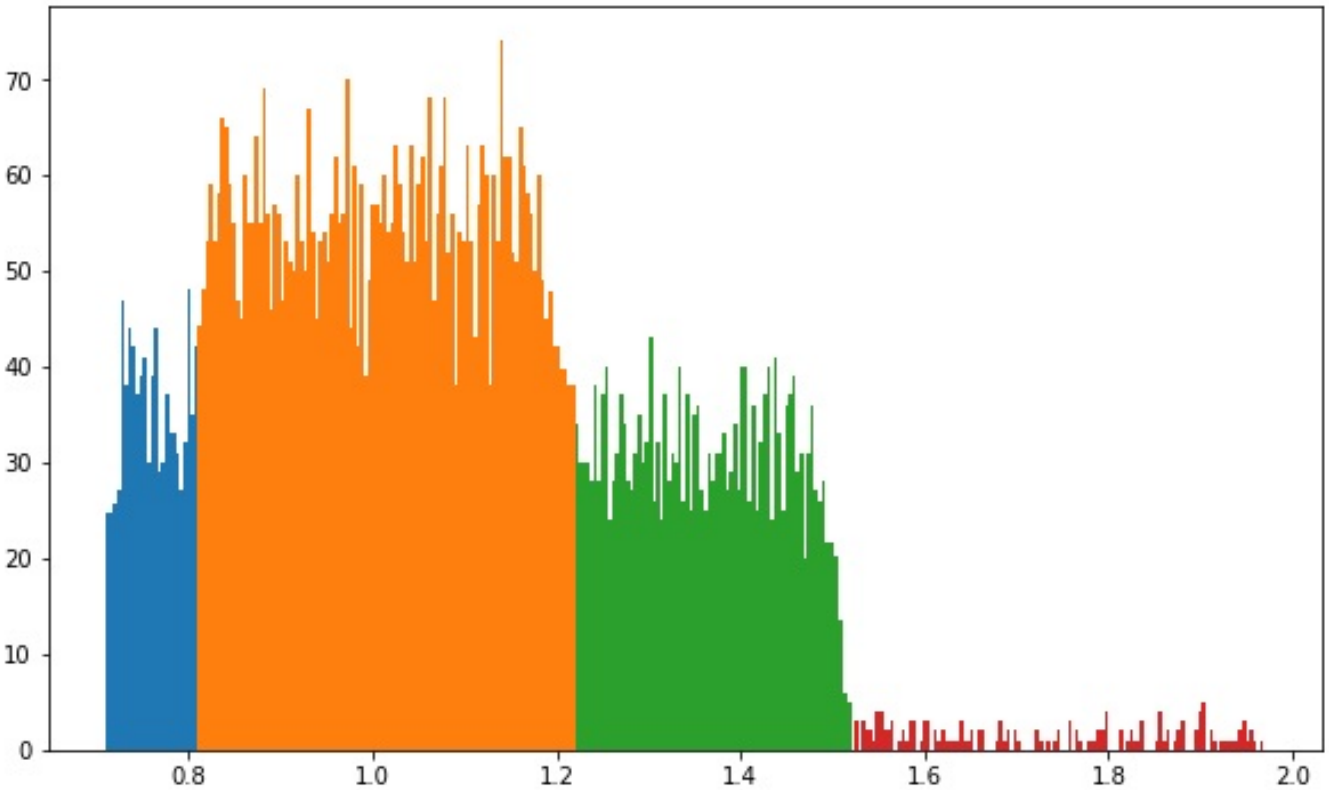

Распределение значений признака f

Предобработка

Модель	Внутреннее расстояние	Внешнее расстояние	Индекс Данна
$k - means^{++}$ 5	18,7	28,9	1,15
$k - means^{++}$ 4	15,9	28,1	1,31
$k - means^{++}$ 3	19,4	23,9	1,05
Пороговая классификация	**20,2**	**27,4**	**1,23**

Сравнение метрик качества $k - means^{++}$ для разного количества кластеров

Ядро модели

Линейная регрессия

$$\frac{1}{l}\sum_{i=1}^{l}(\langle \omega, x_i\rangle - y_i)^2 \to \min_{\omega}.$$

Градиентный бустинг

$$a_N(x) = \sum_{n=0}^{N}\gamma_n b_n(x) - \text{взвешенная сумма базовых алгоритмов}$$

$$\sum_{i=1}^{l} L(y_i, a_{N-1}(x_i) + \gamma_N b_N(x_i)) \to \min_{b_N,\gamma_N}.$$

Метрики оценки качества

Критерии качества регрессионной модели

- $MSE(a, X) = \frac{1}{l} \sum_{i=1}^{l} (a(x_i) - y_i)^2$
- $R^2(a, X) = 1 - \frac{\sum_{i=1}^{l} (a(x_i) - y_i)^2}{\sum_{i=1}^{l} (y_i - \bar{y})^2}$
- $MAE(a, X) = \frac{1}{l} \sum_{i=1}^{l} |a(x_i) - y_i|$
- $MAPE(a, X) = 100\% \times \frac{1}{l} \sum_{i=1}^{l} \frac{|a(x_i) - y_i|}{|y_i|}$

Сравнение результатов

Модель	MSE	R^2	MAE	MAPE
LinearRegression	61564	0,516	307	20%
$k - means^{++}$ & LinearRegression	45671	0,634	260	17,7%
f-clas & LinearRegression	43282	0,652	248	17,3%
f-clas & LightGBM	24467	0,808	224	13,6%
LightGBM	**22009**	**0,827**	**196**	**12%**

Показатели качества построенных моделей

Индикация проблем

Мониторинг портфеля объектов строительства

Результат работы модели на первое июня показал, что доля объектов в красной зоне около 1,5%, а объектов в желтой зоне порядка 20%

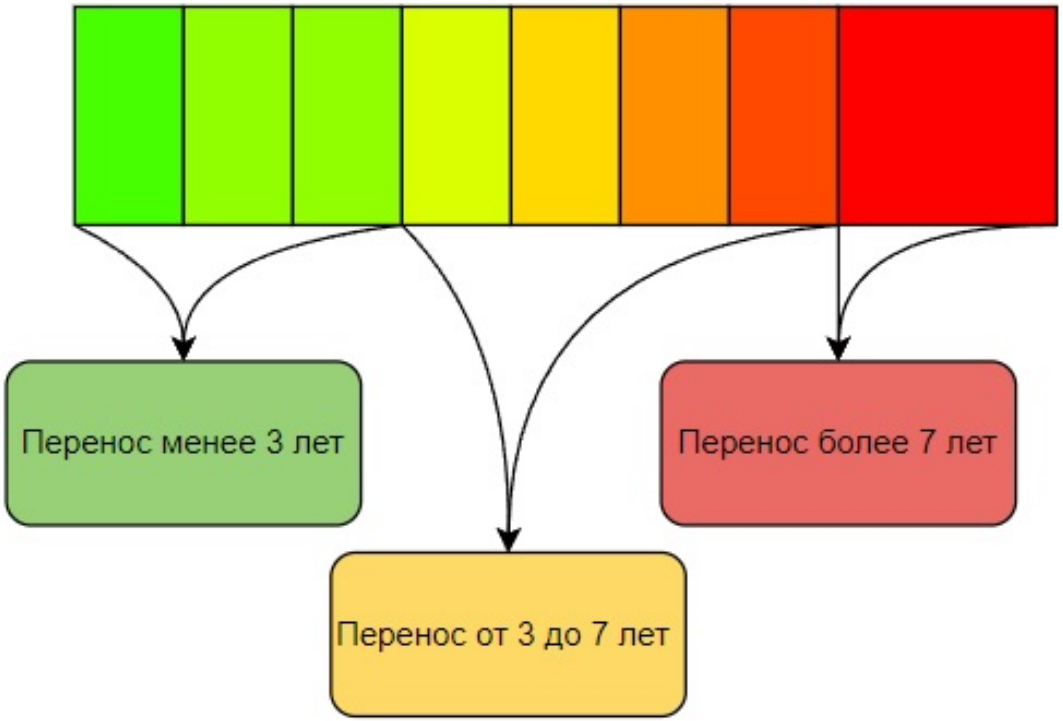

Цветовая индикация

Экономический эффект

Необходимость мониторинга

- Риски только по одному объекту могут составлять более 25 млрд. руб.
- Ручной мониторинг отделом из 10 специалистов обойдется порядка 30 млн. руб ежегодно
- Отношение составляет менее промилле от потенциальной суммы риска только по одному проекту

Плюсы автоматизации

- Возможность сэкономить около 80% трудового ресурса аналитиков
- Стоимость внедрения решения не превышает 5 млн. руб. при существовании возможности масштабирования
- Стоимость обслуживания около 1 млн. ежегодно с учетом всего жизненного цикла

Выносится на защиту

Полученные результаты

- Реализованы методы прогнозирования даты фактической готовности объектов жилищного строительства
- Предложены методы предварительной предобработки данных для повышения качества прогноза модели
- Результаты работы алгоритмов показывают состоятельность подхода и репрезентативность результата

Дальнейшие исследования

- Возможно обобщение модели на другие важные для проектного мониторинга признаки
- Переход к прогнозированию динамически изменяющихся показателей
- Обогащение признакового пространства показателями импортозависимости